




Document de synthèse : Revue d'un article scientifique sur le clustering de séries temporelles zero-inflated

1. Présentation de l'article

Titre : *Zero-Inflated Time Series Clustering via Ensemble Thick-Pen Transform*

Auteurs : Minji Kim, Hee-Seok Oh, Yaeji Lim

Date de publication : Février 2023

Journal : *Journal of Classification (Springer)*

Cet article propose une nouvelle approche de clustering spécifiquement adaptée aux séries temporelles présentant une forte proportion de valeurs nulles, appelées *zero-inflated time series*. L'objectif principal des auteurs est de surmonter les limites des méthodes classiques de clustering lorsqu'elles sont appliquées à ce type de données.

2. Contexte et problématique

Dans de nombreuses applications réelles, les séries temporelles sont constituées de comptages comportant un grand nombre de zéros. Ce phénomène de *zero-inflation* rend les méthodes de clustering traditionnelles inefficaces pour plusieurs raisons :

- Les distances classiques (euclidienne, DTW, etc.) deviennent peu informatives lorsque les séries sont dominées par des zéros.
- Les modèles paramétriques (Poisson, binomiale négative, etc.) ne s'ajustent pas correctement lorsqu'il existe une inflation de zéros.
- Le bruit et les irrégularités temporelles compliquent l'identification de tendances significatives.

Ces limitations motivent la recherche de méthodes capables d'extraire des formes globales ou des tendances, plutôt que de se baser uniquement sur les valeurs brutes. C'est dans ce contexte que s'inscrit la méthode proposée par Kim, Oh et Lim.

3. Solution proposée : Ensemble Thick-Pen Transform (ETPT)

Les auteurs introduisent une technique de transformation non paramétrique, appelée **Ensemble Thick-Pen Transform (ETPT)**, permettant de représenter une série temporelle de manière plus robuste en présence de nombreux zéros.

Principes fondamentaux de la méthode

1. Thick-Pen Transform (TPT)

La série est transformée à l'aide d'un procédé qui consiste à "épaissir" le tracé de la courbe (thick pen).

Cette transformation permet :

- d'atténuer l'impact des zéros répétés,
- de réduire le bruit,
- de faire ressortir les tendances globales.

2. Ensemble de transformations (ETPT)

Pour renforcer la robustesse de la méthode, plusieurs TPT sont appliquées avec différentes épaisseurs de trait. L'ensemble de ces représentations capture à la fois des motifs larges et des détails fins.

3. Clustering final

Après transformation, on peut appliquer n'importe quelle méthode de clustering classique (k-means, agglomératif, k-medoids...).

La transformation rend les distances plus pertinentes et améliore significativement la qualité des regroupements.

Intérêts de la méthode

- Approche simple, intuitive et non paramétrique.
- Excellente robustesse aux zéros et au bruit.
- Compatible avec les algorithmes de clustering usuels.
- Applicable à des données hétérogènes et irrégulières.
- Ne nécessite aucun modèle statistique complexe.

4. Données utilisées dans l'article

L'étude empirique repose sur :

1. Données réelles de comptage du nombre de pas (activité humaine).

Les valeurs nulles y sont fréquentes (journées d'inactivité), ce qui en fait un exemple typique de série zero-inflated.

2. Données réelles de cas quotidiens de COVID-19.

Ces séries présentent également de fortes irrégularités, des périodes prolongées à zéro et des phases de variations rapides.

Les auteurs comparent ETPT aux méthodes traditionnelles et montrent son efficacité sur des données réelles et simulées.

5. Principaux résultats

Les résultats présentés dans l'article mettent en avant les performances de la méthode ETPT :

- Le clustering obtenu est plus stable que celui produit par les distances classiques.
- ETPT identifie correctement les groupes de séries même lorsque la proportion de zéros est très élevée.
- Les tendances structurelles des séries sont mieux capturées après transformation.
- Sur les données COVID comme sur les données de pas, la méthode parvient à regrouper les séries selon des comportements temporels cohérents.
- Les auteurs démontrent une amélioration nette par rapport à des approches telles que k-means euclidien, DTW, autocorrélation ou transformation de Fourier.

6. Référence logicielle (GitHub)

Un dépôt GitHub accompagne l'article :

GitHub - mjkim1001/ZITS: This study develops a new clustering method for high-dimensional zero-inflated time-series data by proposing a similarity measure based on Thick Pen Transform.

 <https://github.com/mjkim1001/ZITS/tree/main>

Il contient :

- les fonctions R permettant de réaliser la transformation ETPT,
- des exemples d'utilisation,
- des scripts reproductibles associés aux expériences de l'article.

Ce dépôt constitue une ressource directe pour l'implémentation dans le cadre d'un projet ou d'un TER.

7. Pertinence de cette méthode pour notre projet

Notre projet consiste à appliquer des méthodes de clustering à des séries temporelles représentant les dénombrements de **320 espèces de phytoplancton observées toutes les deux semaines entre 2015 et 2024**, avec une très forte proportion de valeurs nulles.

La méthode ETPT est particulièrement adaptée à ce contexte pour les raisons suivantes :

1. Gestion naturelle de l'inflation de zéros

ETPT est spécifiquement conçue pour les séries dominées par des zéros, comme c'est le cas pour nos données où certaines espèces n'apparaissent que rarement.

2. Réduction du bruit et amélioration de la lisibilité des tendances

Les données écologiques sont intrinsèquement irrégulières ; ETPT permet de faire ressortir les motifs globaux (saisonnalité, apparition ponctuelle).

3. Compatibilité avec les algorithmes de clustering usuels

Après transformation, des méthodes simples comme k-means peuvent être utilisées efficacement.

4. Méthode non paramétrique, donc flexible

Pas besoin d'hypothèses fortes sur la distribution des comptages (Poisson, binomiale négative, etc.), ce qui évite les difficultés fréquentes dans les modèles pour données zero-inflated.

5. Existence d'un code disponible

Grâce au dépôt GitHub, la méthode est immédiatement exploitable sans implémentation complexe.

Compte tenu de ces caractéristiques, ETPT apparaît comme une approche robuste et adaptée au projet de clustering des séries temporelles du phytoplancton.